الجامعة السورية الخاصة
كلية هندسة الذكاء الاصطناعي
قسم الذكاء الصنعي وعلوم البيانات

Saniva - AI for Early Hope

أعدّ هذا التقرير لإنجاز

مشروع التخرج 2 في اختصاص الذكاء الصنعي وعلوم البيانات

اعداد الطالب:

ينـال عمـاد الشـوفي

اشراف:

الدكتورة ماجـدة البكور

العام الدراسي 2027/2026

إقرار المشرف

أشهد بأن إعداد هذا المشروع الموسوم .....
.....
والمعد من قبل الطلاب.....
.....
قد تم تحت اشرافي في قسم هندسة الذكاء الصنعي وعلوم البيانات – كلية هندسة الذكاء الاصطناعي، وهو جزء من متطلبات نيل شهادة الإجازة في الهندسة / هندسة الذكاء الصنعي وعلوم البيانات.
المرتبة العلمية..... الاسم.....التوقيع
التاريخ

قائمة المحتويات

إقرار المشرف..... II
قائمة المحتويات..... III
قائمة الأشكال..... IV
قائمة الجداول..... IV
قائمة المعادلات..... IV
قائمة بأهم المصطلحات..... V
الفصل الأول - المقدمة..... 2
1.1 تمهيد..... 2
2.1 مشكلة البحث..... 2
3.1 الهدف من المشروع..... 3
4.1 هيكلية البحث..... 3
الفصل الثاني – الأدبيات السابقة..... 6
1.2 الدراسة المرجعية..... 6
2.2 جدول الدراسات المرجعية..... 13
الفصل الثالث - إدارة المشروع..... 18
1.3 المقدمة..... 18
2.3 ميثاق المشروع..... 18
3.3 وثيقة نطاق العمل..... 19
4.3 خطة المشروع – مخطط غانت..... 20
5.3 إدارة المخاطر..... 21
6.3 إدارة النماذج والتجارب..... 21
7.3 خطة العمل..... 21
8.3 الخلاصة..... 22
الفصل الرابع - المنهجية..... 24
1.4 مقدمة..... 24
2.4 مراجعة تقنية للأدبيات..... 24
3.4 الفجوات على المستويين المعرفي والتطبيقي..... 25
4.4 منهجية العمل..... 25
5.4 مجموعة المعطيات المستخدمة..... 26
1.5.4 Vindr-Mammo Dataset..... 26
2.5.4 خصائص التسميات..... 26
3.5.4 التحديات في البيانات..... 27
6.4 تحضير مجموعة المعطيات..... 28
1.6.4 تنظيف البيانات..... 28
2.6.4 دمج البيانات الجدولية..... 28

3.6.4 إنشاء View Mapping 29
4.6.4 معالجة عدم توازن الفئات 29
7.4 البيئة التقنية والتنفيذية 32
1.7.4 الأجهزة والبنية التحتية 32
2.7.4 البرمجيات والمكتبات 33
3.7.4 إدارة النماذج والتجارب 33
8.4 المنهجية المقترحة 34
1.8.4 النظرة العامة 34
7.8.4 معمارية النموذج الكلية 36
9.4 مقاييس الأداء 37
1.9.4 مقاييس التصنيف الأساسية 37
2.9.4 مقاييس متعددة الفئات 38

قائمة الأشكال

الشكل 1.3: مخطط غانت 20

قائمة الجداول

الجدول 1.3: ميثاق المشروع 18
الجدول 2.3: وثيقة نطاق العمل 19
الجدول 3.3: جدول المخاطر المحتملة 21
الجدول 4.4: خصائص مجموعة بيانات Vindr-Mammo 26
الجدول 5.4: BI-RADS Oversampling 30
الجدول 6.4: البرمجيات والمكتبات 33

قائمة المعادلات

معادلة 1.4: MinMaxScaler 29
معادلة 2.4 : Effective Number Weighting 29
المعادلة 3.4: الدقة 37
المعادلة 4.4: التنبؤ الإيجابي 37
المعادلة 5.4: الاسترجاع 37
المعادلة 6.4: F1 Score 38

قائمة بأهم المصطلحات

المصطلح التقني	الترجمة العربية	الاختصار	المعنى
Artificial Intelligence	الذكاء الاصطناعي	AI	مجال يهدف إلى تمكين الأنظمة من محاكاة الذكاء البشري
Deep Learning	التعلم العميق	DL	فرع من التعلم الآلي يعتمد على الشبكات العصبية العميقة
Machine Learning	التعلم الآلي	ML	خوارزميات تتعلم الأنماط من البيانات
Convolutional Neural Network	الشبكة العصبية الالتفافية	CNN	شبكة متخصصة في معالجة الصور
Mammography	تصوير الثدي الشعاعي	—	تقنية تصوير طبية للكشف عن سرطان الثدي
Breast Cancer	سرطان الثدي	—	مرض ناتج عن نمو غير طبيعي لخلايا الثدي
BI-RADS	نظام تقارير تصوير الثدي	BI-RADS	معيار طبي لتصنيف نتائج الماموغرام
Breast Density	كثافة الثدي	—	نسبة النسيج الغدي إلى الدهني في الثدي
Multi-task Learning	التعلم متعدد المهام	MTL	تدريب نموذج واحد على عدة مهام متزامنة
Class Imbalance	عدم توازن الفئات	—	تفاوت كبير في عدد العينات بين الفئات
EfficientNetB4	—	EfficientNet B4	شبكة عميقة فعالة لاستخراج السمات
Backbone Network	الشبكة الأساسية	—	الجزء المسؤول عن استخراج الميزات
Cross-Attention	الانتباه المتقاطع	—	آلية انتباه لدمج معلومات من مصادر مختلفة
Efficient Cross Attention	الانتباه المتقاطع الكفؤ	ECA	آلية دمج متعددة الرؤى بكلفة حسابية أقل
Gated Fusion Layer	طبقة الدمج البوابي	GFL	طبقة تتحكم بتدفق المعلومات بين السمات
Multi-view Learning	التعلم متعدد المناظر	—	دمج معلومات من زوايا تصوير مختلفة
Feature Fusion	دمج السمات	—	الجمع بين تمثيلات متعددة للبيانات
Large Language Models	نماذج اللغة الكبيرة	LLMs	نماذج لغوية قادرة على توليد نصوص طبية
Tabular Encoder	مشفّر البيانات الجدولية	—	طبقة لمعالجة البيانات الرقمية
Vindr-Mammo Dataset	مجموعة بيانات فيندر-مامو	—	قاعدة بيانات ماموغرام سريرية
DICOM	تنسيق الصور الطبية	DICOM	معيار عالمي لتخزين الصور الطبية
Transfer Learning	التعلم بالنقل	TL	استخدام نموذج مدرب مسبقًا لمهمة جديدة
Oversampling	زيادة العينات	—	مضاعفة عينات الفئات النادرة
Data Augmentation	تعزيز البيانات	—	توليد عينات جديدة من البيانات الأصلية
Effective Number Weighting	الوزن الفعال للفئات	ENW	أسلوب لمعالجة عدم توازن البيانات
Focal Loss	خسارة التركيز	—	دالة خسارة تعزز تعلم الفئات النادرة

Multi-view Integration	دمج المناظر المتعددة	—	دمج معلومات صور مأخوذة من زوايا مختلفة
Left Cranio-Caudal	المنظر القحفي الذيلي الأيسر	L_CC	تصوير الثدي الأيسر من الأعلى
Right Cranio-Caudal	المنظر القحفي الذيلي الأيمن	R_CC	تصوير الثدي الأيمن من الأعلى
Left Medio-Lateral Oblique	المنظر المائل الأيسر	L_MLO	تصوير جانبي مائل للثدي الأيسر
Right Medio-Lateral Oblique	المنظر المائل الأيمن	R_MLO	تصوير جانبي مائل للثدي الأيمن
API	واجهة برمجة التطبيقات	API	وسيلة ربط بين الأنظمة البرمجية
GPT-4o	نموذجGPT-4o	GPT	نموذج لغوي لتوليد النصوص الطبية

الفصل الأول

المقدمة

الفصل الأول ـ المقدمة

1.1 تمهيد

يُعد سرطان الثدي أحد أكثر الأمراض الخبيثة انتشاراً بين النساء عالمياً، حيث سجلت منظمة الصحة العالمية (WHO) أكثر من 2.3 مليون حالة إصابة جديدة عام 2022، مما يجعله السبب الرئيسي لوفيات السرطان بين النساء في معظم الدول [1]. وفي العالم العربي، ولا سيما دول الخليج، تشهد معدلات الإصابة ارتفاعاً ملحوظاً، الأمر الذي يُبرز الحاجة إلى أنظمة كشف مبكر دقيقة ومتاحة [2].

يُعتبر التصوير الشعاعي للثدي (Mammography) المعيار الذهبي للكشف المبكر، لقدرته على اكتشاف الأورام قبل ظهورها سريرياً بسنوات [3]. إلا أن التشخيص اليدوي يواجه تحديات رئيسية، أبرزها الخطأ البشري، حيث قد تصل معدلات التشخيص الخاطئ إلى 30% في حالات كثافة الثدي العالية [4]، إضافة إلى النقص العالمي في الأخصائيين الشعاعيين، خصوصاً في الدول النامية [5]، وما يرافق ذلك من عبء اقتصادي كبير على الأنظمة الصحية[6] .

في هذا السياق، برز الذكاء الاصطناعي وأنظمة CADe/CADx كحل واعد لدعم القرار الطبي، مع قدرتها على تحقيق أداء يضاهي دقة الأخصائيين في مهام محددة [7]. ومع ذلك، لا تزال هذه الأنظمة تعاني من قصور في التعامل مع البيانات غير المتوازنة، ودمج المناظر المتعددة، وتوفير تفسير سريري وتقرير طبي متكامل. وانطلاقاً من ذلك، تقدم هذه الأطروحة نظام Sanvia كإطار ذكي متكامل يعتمد على التعلم العميق ونماذج اللغة البصرية لتقديم حل تشخيصي شامل ومُفسَّر سريرياً.

2.1 مشكلة البحث

على الرغم من التقدم الملحوظ في مجال الذكاء الاصطناعي الطبي، لا تزال الأنظمة الحالية تعاني من قصور جوهري يحد من فعاليتها في البيئات السريرية الواقعية، إذ تواجه تحديات هندسية وسريرية معقدة تبدأ بمشكلة عدم توازن الفئات الحاد في مجموعات بيانات التصوير الشعاعي للثدي (ماموغرام)، حيث تسيطر الحالات الطبيعية (BI-RADS 1–2) على الغالبية العظمى بينما تشكل الحالات المشتبهة نسباً ضئيلة للغاية (مثل تمثل فئة BI-RADS 4 نحو 0.27% فقط في مجموعة Vindr-Mammo)، مما يحرف النماذج التعليمية نحو الفئات الأكثر تكراراً ويُضعف قدرتها على اكتشاف الحالات الحرجة بسبب معالجة دالة الخسارة القياسية للأخطاء بمساواة دون مراعاة الأهمية السريرية

للفروق بين الخطأ الايجابي والخطأ السلبي. فضلاً عن ذلك، تعاني الأنظمة من قصور في آليات دمج المناظر المتعددة، إذ تعالج بعضها كل منظور (CC وMLO للثديين) بشكل منفرد فتفقد الارتباطات المكانية بينها، أو تعتمد على أساليب دمج بدائية مثل Concatenation دون مراعاة الأهمية النسبية لكل منظر في السياق التشريحي. علاوة على ذلك، تقتصر معظم الأنظمة على مرحلة التصنيف الرقمي دون الانتقال إلى توليد تقارير طبية منهجية باللغة الطبيعية، مما يخلق فجوة بين المخرجات الآلية والتوثيق السريري المطلوب ويفرض تدخلاً بشرياً إضافياً. وأخيراً، تظل الفجوة واسعة في تخصيص هذه الأنظمة للسياق العربي والمحلي، إذ تفتقر المنطقة إلى حلول ذكاء اصطناعي في الماموغرام التي تستند إلى البيانات السكانية المحلية أو توفر واجهات وتقارير طبية باللغة العربية، مما يحد من إمكانية اعتمادها في الأنظمة الصحية العربية.

3.1 الهدف من المشروع

يهدف هذا المشروع إلى تطوير نظام ذكي متكامل لتشخيص سرطان الثدي آليًا يعتمد على تقنيات التعلم العميق ونماذج اللغة المتقدمة، وذلك من خلال تحليل صور التصوير الشعاعي للثدي من عدة مناظر تصويرية ودمجها بطريقة فعالة تحاكي سير العمل السريري الحقيقي. يسعى النظام إلى معالجة التحديات الجوهرية، وتحسين دقة اكتشاف الحالات الحرجة ذات الأهمية السريرية العالية. كما يهدف المشروع إلى تجاوز الاقتصار على التصنيف الرقمي عبر توفير تفسير سريري واضح وتوليد تقارير طبية نصية تلقائية باللغة الطبيعية، بما يساهم في تقليص الفجوة بين المخرجات الآلية ومتطلبات التوثيق السريري العملي. ويطمح هذا العمل إلى تقديم حل تشخيصي موثوق وقابل للتطبيق في البيئات السريرية الواقعية، يدعم الأخصائيين الشعاعيين في اتخاذ قرارات تشخيصية أسرع وأكثر دقة، مع إرساء أساس قابل للتطوير نحو دعم السياق العربي والمحلي في أنظمة الذكاء الاصطناعي الطبية.

4.1 هيكلية البحث

تنظم هذه الأطروحة في سبعة فصول رئيسية، حيث يقدم الفصل الأول تمهيداً لموضوع سرطان الثدي وأهميته، يليه تحديد مشكلة البحث وعرض النتائج والإسهامات العلمية والهندسية لهذه الدراسة.
يستعرض الفصل الثاني الأدبيات السابقة والتطور التاريخي لأنظمة وتطبيقات التعلم العميق في الماموغرام، مع تحديد الفجوات البحثية التي تهدف هذه الدراسة إلى سدها. ثم يأتي الفصل الثالث الذي يهتم بإدارة المشروع حيث يستعرض ميثاق المشروع ونطاقه ثم إدارة المخاطر المحتملة بالإضافة الى توثيق التجارب والنتائج. أما الفصل الرابع فيقدم التفاصيل الكاملة للمنهجية المقترحة بدءاً من مراجعة تقنية للمفاهيم الأساسية، مروراً بتحليل مجموعة البيانات Vindr-Mammo، ووصولاً إلى البنية المعمارية التفصيلية لنظام Sanvia، مع شرح شامل لآليات دمج المناظر، ومعالجة البيانات،

واستراتيجيات التدريب ومقاييس الأداء. يصف الفصل الخامس إعدادات التجارب وتقسيم البيانات، ويعرض النتائج الكمية لتصنيف BI-RADS وDensity. يركز الفصل السادس على الجانب التطبيقي للنظام، بدءاً من ربط APIs لنماذج اللغة، وتوليد التقارير النصية، وتجميع التقرير الشامل، مع تقييم سريري لجودة النتائج. وأخيراً، يقدم الفصل السابع تلخيص المساهمات الرئيسية، والإجابة على أسئلة البحث، ومناقشة القيود، مع تقديم توصيات مستقبلية لتحسين النموذج، وتوسيع النظام، وتعزيز التحقق السريري، ومراعاة الاعتبارات الأخلاقية والاجتماعية.

الفصل الثاني

الأدبيات السابقة

الفصل الثاني – الأدبيات السابقة

1.2 الدراسة المرجعية

تنوّعت الجهود البحثية في مجال الذكاء الاصطناعي لتحليل صور الماموغرام وتشخيص سرطان الثدي بين نماذج التعلم العميق متعددة الوسائط، واستراتيجيات دمج الرؤى المتعددة، والشبكات التلافيفية المخصصة لتصنيف كثافة الثدي وفئاتBI-RADS ، ونماذج كشف الآفات وتقسيمها، إضافةً إلى الأساليب التي تهدف إلى تفسير قرارات النماذج وتحسين قابليتها للتعميم. وقد شكّلت قواعد البيانات المعيارية نقطة انطلاق أساسية لتطوير هذه النماذج وتقييمها، إذ قدّمت دراسة [8] مجموعةVinDr-Mammoبوصفها قاعدة بيانات معيارية واسعة النطاق لتطوير أنظمة التشخيص بمساعدة الحاسوب في الماموغرام الرقمي، وتضم 5,000 فحص بأربعة إسقاطات معيارية لكل فحص، مع تقييمات على مستوى الثدي وتعليقات موضعية للآفات، بالاعتماد على قراءات اختصاصيي الأشعة والتحكيم عند الاختلاف. وتمثل هذه المجموعة مرجعًا مهمًا لتطوير وتقييم نماذج الكشف عن الآفات والتصنيف متعدد المستويات، إذ تتيح الاستفادة من المعلومات متعددة الرؤى والتعليقات الموضعية في التدريب والتحقق، مع ضرورة مراجعة تعريفات التسميات وشروط الوصول وتقسيمات المرضى قبل استخدامها.

وفي إطار الاستفادة من المعلومات المتاحة في الإسقاطات المختلفة، تناولت دراسة [14] تطوير إطار تكيفي لدمج منظري CC و MLOباستخدام فرعين متبقيين مستقلين وآلية Gated Cross-View Fusion، إلى جانب الانتباه متعدد الرؤوس والانتباه المكاني، مع استخدام Otsu لاستخراج منطقة الثدي و CLAHEلتحسين التباين؛ وحققت دقة بلغت 92.116% على VinDr-Mammo و95.556% علىINbreast ، إذ ارتفعت الدقة على VinDr-Mammo من 74.274% عند استخدام الفرعين مع دمج بسيط إلى 81.051% بعد إضافة الدمج البوابي، ثم 85.754% بعد إضافةMulti-Head Self-Attention، وصولًا إلى 92.116% بعد إضافةSpatial Attention ، مما يبرز أهمية تصميم آليات متخصصة للاستفادة من المعلومات المكملة بين الإسقاطات، مع بقاء الحاجة إلى اختبار دمج الصور الأربع وتصنيف BI-RADS وكثافة الثدي بصورة مستقلة.

وبالاستناد إلى فكرة دمج الإسقاطات المتعددة، قارنت دراسة [16] استراتيجيات متعددة الرؤى للكشف عن سرطان الثدي، من خلال اقتراح استراتيجيتي(MDV) Merged Dual-View ، التي تدمج صور CC و MLOفي صورة واحدة قبل إدخالها إلى النموذج، و Dual-Branch Ensemble

(DBE)، التي تعالج كل إسقاط بصورة مستقلة ثم تدمج التنبؤات؛ واختبرت الاستراتيجيتين على ست مجموعات بيانات، هي CSAW-CC و CMMDو VinDr-Mammoو KAU-BCMD و NLBSوRSNA، باستخدام نماذج مدرّبة مسبقًا مثل ResNet و DenseNetو EfficientNet و MobileNetو VGG19وViT، مع معالجة عدم توازن الفئات باستخدام Balanced Undersampling.وأظهرت النتائج أن MDV حققت AUC بلغ 0.9051 باستخدامVGG19 ، بينما حققت DBE قيمة AUC بلغت 0.8042 باستخدامResNet50 ، وسجلت DenseNet قيمة F1 بلغت 0.7756 و AUCبلغ 0.8033؛ كما أظهرت DBE استقرارًا أفضل في التعميم عبر مجموعات البيانات، رغم استمرار فجوة الأداء بين البيانات المرئية أثناء التدريب والبيانات غير المرئية، مما يوضح أهمية تقييم النماذج على مجموعات مستقلة وعدم الاكتفاء بالنتائج الداخلية.

وفي اتجاه أكثر تخصصًا نحو دمج الصور الأربع على مستوى الفحص، تناولت دراسة [24] تصنيف الماموغرام باستخدام تقنيات التعلم العميق متعددة الرؤى القائمة على الرسوم البيانية والمحولات، بهدف دمج معلومات الإسقاطات الأربعة وإنتاج تصنيف على مستوى الفحص كاملًا بدل معالجة كل صورة بمعزل عن الأخرى. وتكتسب هذه المقاربة أهمية خاصة عند تصميم نماذج تستقبل RCC و RMLO و LCCو LMLOمعًا، إذ تتيح دراسة العلاقات بين الصور بدل الاكتفاء بدمج تنبؤاتها النهائية، إلا أن المعلومات المتاحة في الدراسة المرجعية لا تتضمن نتائج رقمية مفصلة أو أسماء مجموعات البيانات وأحجامها على نحو يسمح بإسناد قيم أداء محددة إلى هذه المعماريات.

ومن ناحية التعلم المسبق متعدد الرؤى، قدّمت دراسة [15] نموذجGLAM ، وهو نموذج للرؤية واللغة يعتمد على مشفر الصور DINOv2 ViT-B ومشفر النصوصBioClinical-BERT ، ويجمع بين المحاذاة العامة متعددة الوسائط والمحاذاة الموضعية الموجّهة هندسيًا على المحور الأمامي الخلفي (AP)، بهدف الاستفادة من العلاقة الهندسية بين إسقاطي CC و MLOوتحسين كفاءة البيانات والمتانة والتعميم؛ ودُرّب النموذج على مجموعات EMBED و VinDr-MammoوRSNA-Mammo، مع استخدام الانتباه المتقاطع متعدد الرؤوس لمحاذاة الرقع الصورية بالمقاطع المكانية، وتقييمه باستخدام AUCوالدقة المتوازنة في إعدادات Zero-Shot و Linear ProbingوFull Fine-Tuning، بما في ذلك حالات استخدام نسب محدودة من بيانات التدريب، وأظهرت الدراسة تحسنًا في الأداء ضمن إعدادات البيانات القليلة وقدرةً على التعميم عبر مجموعات مختلفة.

وعلى مستوى دمج الصور مع البيانات السريرية، قدّمت دراسة [13] إطارًا متعدد الوسائط يجمع الشبكات التلافيفية ومحولات الرؤية وآليات الانتباه العابر للوسائط، مع دمج هرمي ديناميكي ووحدة

اهتمام بالمناطق ذات الصلة، بهدف تحسين تشخيص سرطان الثدي بالاستفادة من صور الماموغرام والمتغيرات السريرية؛ واستخدمت مجموعات CBIS-DDSM و INbreastو BCDR-D01 وCMMD، وحققت دقة بلغت 94.6% و AUCبلغ 0.963 على مجموعة التحقق، بينما بلغت قيمة AUCالخارجية 0.947 على BCDR-D01 و0.939 علىCMMD ، مع الإشارة إلى أن المتغيرات السريرية المستخدمة كانت اصطناعية، مما يحدّ من إمكانية تعميم النتائج المتعلقة بأثر البيانات السريرية الحقيقية.

وفي مجال تصنيف كثافة أنسجة الثدي، طوّرت دراسة [17] نظامًا منخفض التكلفة ومفتوح المصدر يعتمد على شبكة تلافيفية مخصصة CD-CNN وطبقة تصنيف Extreme Learning Machine (ELM)، بهدف تصنيف الكثافة إلى الفئات الأربع A–D وفق تصنيفBI-RADS ؛ واستخدمت 10,371 صورة من 2,472 مريضة، مع اختبار خارجي على مجموعة mini-MIAS التي تضم 322 صورة، وجرى تصغير الصور إلى 128×128 بكسل وتطبيق التحقق المتقاطع بعشر طيات مع فصل بيانات كل مريضة ضمن مجموعة واحدة لتجنب تسرب البيانات. وحقّق النموذج الأفضل دقة داخلية بلغت 95.4% وحساسية 92.5% ونوعية 98.0%، مع معامل اتفاق موزون بلغ 0.90، بينما انخفضت الدقة على المجموعة الخارجية إلى 73.9%، مما يبرز أهمية التحقق الخارجي عند تقييم قابلية التعميم.

وفي السياق نفسه، قارنت دراسة [21] أربع معماريات تلافيفية مدرّبة مسبقًا، هي ResNet50 و InceptionV3و DenseNet121وXception، باستخدام 57,282 صورة من 9,621 امرأة، مع اختبار خارجي على 500 حالة من مجموعةRSNA Breast Cancer Detection ؛ واعتمدت على تغيير حجم الصور إلى 224×224 بكسل، وموازنة التباين باستخدامHistogram Equalization ، والتطبيع وتعزيز البيانات، ثم دمج تنبؤات الصور المتعددة باستخدام Soft Voting على مستوى الفحص. وحقق نموذج InceptionV3 أفضل أداء وفقAverage Precision ، حيث بلغت قيم AP للفئات A–D على مجموعة الاختبار الداخلية 0.952 و0.953 و0.857 و0.895 على التوالي، بينما بلغت القيم الخارجية 0.902 و0.960 و0.896 و0.946، مع معامل اتفاق Cohen’s kappa بلغ 0.803، مما يؤكد أهمية تقييم كل فئة على حدة وعدم الخلط بين AP والدقة الكلية.

ولمعالجة التحديات المرتبطة باختلاف تقنيات التصوير والمجموعات السكانية، تناولت دراسة [16] تطوير طريقة تعلم عميق قابلة للتعميم عبر تقنيات التصوير المختلفة والمجموعات السكانية، بالاعتماد على معمارية ResNet-34 المنفذة باستخدامTensorFlow 2 ، وباستخدام 69,697 فحصًا و451,642 صورة من 23,057 مشاركة، جُمعت من أربعة مواقع مستشفيات. وقارنت الدراسة التدريب

على صور التصوير الرقمي كامل الحقل (FFDM) وحدها بالتدريب الذي يجمع FFDM مع تقنية DS2، فبلغت الدقة في تصنيف فئات الكثافة الأربع 80.5% على FFDM و79.4% على DS2 عند التدريب على FFDM وحدها، بينما وصلت إلى 82.3% على كلتا التقنيتين عند التدريب عليهما معًا، وتراوحت الدقة في تحليلات المجموعات العرقية بين 80.2% و83.3% دون الإبلاغ عن فروق جوهرية بين المجموعات المدروسة. وتؤكد هذه النتائج أهمية تنوع أجهزة التصوير والبيانات السكانية في اختبار النماذج، وضرورة عدم الاكتفاء بالتقييم على مجموعة واحدة عند تطوير نظام يستهدف الاستخدام في بيئات مختلفة.

وبصورة أكثر ارتباطًا بالتصنيف متعدد المستويات وتحديد المناطق ذات الأهمية التشخيصية، قدّمت دراسة [18] نظامًا من مرحلتين يجمع شبكة متعددة المهام لاكتشاف الآفات وتحديد مواقعها وتقسيمها على مستوى الرقع مع نموذج EfficientNet-B0 لتصنيف الثدي اعتمادًا على صور CC و MLO وخرائط الخباثة المستخرجة؛ واستخدمت الدراسة 49,732 صورة من 24,866 ثديًا، مع مجموعات تحقق واختبار خارجية، وحققت AUC بلغ 0.995 على التحقق و0.933 و0.947 على مجموعتي الاختبار الخارجيتين لتمييز الآفات الخبيثة من غير الخبيثة. كما أسهم النظام في خفض الإيجابيات الكاذبة بنسبة 83.1% ورفع نسبة اكتشاف السلبيات الكاذبة بنسبة 54.1% ضمن تحليل فئاتBI-RADS ، بينما تحسن متوسط AUC لدى أطباء الأشعة من 0.870 إلى 0.888 عند الاستعانة بالنظام، مما يدعم جدوى الجمع بين تحديد المناطق المشبوهة والتصنيف النهائي بدل الاعتماد على تصنيف الصورة كاملةً وحده.

وفي مجال كشف الكتل وتصنيفها، اعتمدت دراسة [22] على نموذج YOLOv5-CAD مع نقل التعلم بين مجموعات البيانات، إذ دُرّب النموذج على بيانات CBIS-DDSM و VinDr-Mammoثم ضُبط باستخدامINbreast ، مع معالجة صور DICOM وتحويلها إلى JPEG وإزالة الحواف والمناطق السوداء غير المرغوبة؛ وحققت التجارب قيم mAP بلغت 0.843 عند النقل من CBIS-DDSM و0.840 عند النقل منVinDr-Mammo ، مع قيم Precision بلغت 0.855 و0.829 على التوالي، واستدعاء بلغ 0.774 و0.787، وأزمنة استدلال بلغت 14.8 و16.54 ميلي ثانية للصورة. كما بلغ mAPللنموذج المنقول من CBIS-DDSM إلى INbreast نحو 0.756 على مجموعة MIAS و0.816 على مجموعة سريرية خاصة، مما يدعم استخدام نماذج YOLO لتحديد المناطق التي تحتوي على كتل، مع التأكيد على أن هذه المقاييس تخص الكشف عن الكتل وتصنيفها وليست قياسًا لأداء تصنيف BI-RADS متعدد الفئات.

وفي اتجاه أكثر تخصصًا نحو تحديد الآفات وتقسيمها، اقترحت دراسة [23] إطارًا خفيفًا من مرحلتين يجمع YOLOv5 للكشف عن الكتل مع Depthwise SegNet لتقسيم مناطقها، باستخدام معمارية SegDSC4_90التي تعتمد على الالتفافات القابلة للفصل عمقيًا لتقليل التعقيد الحسابي؛ واختُبر النظام على 1,592 صورة منCBIS-DDSM ، قُسمت إلى 1,231 صورة للتدريب و361 للاختبار، إضافةً إلى مجموعة INbreast مستقلة تضم 107 صور مع أقنعتها. وحقق النموذج mAP@0.5 بلغ 50.3% على CBIS-DDSM و68.2% علىINbreast ، بينما بلغت قيمة Dice للتقسيم 89.4% و87.0% على التوالي، وقيم IoU بلغت 81.0% و77.3%، مع زمن استدلال يقارب 21 ميلي ثانية للصورة باستخدامGPU ؛ وتبرز هذه الدراسة إمكانية فصل مرحلة الكشف عن مرحلة التقسيم لتوفير معلومات مكانية إضافية، دون اعتبار نتائج الكشف والتقسيم دليلًا مباشرًا على كفاءة تصنيف.BI-RADS

أما فيما يتعلق بقابلية تفسير تصنيفBI-RADS ، فقد اقترحت دراسة [28] شبكة Radioport التي تجمع بين السمات الشعاعية (Radiomics) والمخرجات الوصفية الداعمة للقرار بهدف تفسير تصنيف التكلسات في صور الماموغرام، بدل الاكتفاء بإنتاج درجة تصنيف نهائية؛ وتتمثل أهميتها في توفير اتجاه لتطوير نماذج تشرح أسباب التصنيف وتربط النتائج بخصائص الصورة، مع ملاحظة أن المعلومات المتاحة في الدراسة المرجعية لا تتضمن تفاصيل كافية عن حجم مجموعة البيانات أو المعمارية الدقيقة أو مقاييس الأداء الرقمية، كما أن نطاقها يقتصر على التكلسات ولا يمثل جميع أنواع الآفات أو فئات.BI-RADS

ومن جهة تفسير قرارات نماذج تحليل الماموغرام، درست ورقة [20] استخدام التعلم العميق وإسناد السمات لتحديد النتائج ذات الأهمية السريرية ضمن المناطق المحلية من صور الماموغرام عالية الدقة، وقدّمت منهجية CorRELAX التي تربط بين تمثيلات السمات الوسيطة وتنبؤات النموذج لإنتاج خرائط حرارية توضح المناطق المؤثرة في القرار؛ واعتمدت على مجموعة VinDr-Mammo ورقع متعددة المقاييس للآفات، وحققت قيمة F1 بلغت 0.8432 للتكلسات و0.7392 للكتل، بينما بلغ متوسط دقة Pointing Gameنحو 0.6358 عند استخدام خرائط التنبؤ و0.5602 عند استخدام خرائط الارتباط. وتُعد هذه النتائج ذات صلة بإضافة وسائل تفسير مكاني إلى النماذج الطبية، مع ضرورة التمييز بين خرائط الأهمية التي تشرح مواضع تأثير النموذج وأقنعة التقسيم التي تحدد حدود الآفة بدقة.

وفي مجال نماذج الرؤية واللغة الطبية، طوّرت دراسة [26] نموذج Mammo-CLIP بوصفه نموذج أساس للرؤية واللغة مخصصًا للماموغرام، ومدرّبًا على أزواج الصور والتقارير من مجموعات UPMCو VinDr-MammoوRSNA-Mammo، مع استخدام مشفر نصوص

BioClinicalBERTومشفرات صور EfficientNet-B2 وEfficientNet-B5، وخسارة تباينية متعددة الرؤى لمحاذاة التمثيلات الصورية والنصية الأصلية والمعززة. كما اقترحت الدراسة مكوّن Mammo-FActORلربط قنوات الصورة بجمل تصف السمات باستخدام خسارة تباينية، بهدف توفير تفسيرات لغوية مرتبطة بالسمات دون الحاجة إلى صناديق إحاطة مكانية أثناء التدريب. وأظهرت النتائج أداءً واعدًا في مهام تصنيف الكتل والتعلم دون أمثلة والضبط الدقيق، مع تحسن كفاءة استخدام البيانات والمتانة، مما يوفر اتجاهًا بحثيًا إضافيًا لتطوير تمثيلات صورية قابلة للاستفادة في مهام متعددة، رغم أن استخدام هذه النماذج يتطلب مواءمتها مع الأهداف المحددة، ولا سيما تصنيف BI-RADS وكثافة الثدي ودمج الصور الأربع.

وفي سياق توليد الأوصاف والتقارير الطبية من الصور، طوّرت دراسة [25] نموذج ClinicalBLIP لتوليد الأوصاف والتقارير من الصور الطبية بالاعتماد على بنية InstructBLIP والضبط الدقيق متعدد المراحل وتقنية LoRA والتعلم باستخدام المحفزات الطبية؛ واستخدمت مجموعتي IU X-RAY وMIMIC-CXR، مع مشفر بصري من عائلة CLIP ومولد نصيFlan-T5-XL ، وقيّمت النتائج باستخدام BLEU و METEORو .ROUGE-Lوبلغت قيم METEOR و ROUGE-Lنحو 0.570 و0.534 علىIU X-RAY ، ونحو 0.365 و0.313 علىMIMIC-CXR ، مما يشير إلى إمكانية توظيف نماذج الرؤية واللغة في إنشاء أوصاف طبية مساعدة، مع بقاء الحاجة إلى ضمان الدقة الاصطلاحية والسريرية قبل اعتماد المخرجات في سياقات طبية فعلية.

أما دراسة [19] فقد اقترحت إطار C-SRRG لتوليد تقارير أشعة منظمة تراعي تعدد الصور والسياق السريري والمقارنات الزمنية، بالاعتماد على نماذج لغوية متعددة الوسائط مثل Lingshu-7B و MedGemma-4BوCheXagent-3B، مع استخدام LoRA للضبط الدقيق و Hugging Face PEFTو vLLMللتدريب والاستدلال؛ واستندت الدراسة إلى بيانات مستمدة من MIMIC-CXR وCheXpert Plus، وقيّمت التقارير باستخدام مقاييس BLEU و ROUGE-Lو BERTScore و RadGraphو F1-SRRG-BERTوغيرها. وأظهرت النتائج تحسنًا في جودة التقارير، إذ ارتفع F1-SRRG-BERTبمقادير تراوحت بين 2.3 و4.2 نقاط في الملاحظات وبين 1.3 و7.1 نقاط في الانطباعات، كما انخفضت الهلوسات الزمنية من 22.9% إلى 10.7%، مما يبرز أهمية السياق السريري في الأنظمة التي تتجاوز التصنيف إلى تقديم مخرجات تفسيرية.

وفي إطار أوسع لتقييم تطور هذا المجال، قدّمت دراسة [27] مراجعة شاملة للأبحاث التي تناولت التوليد التلقائي لتقارير التصوير الطبي باستخدام التعلم العميق، مستعرضةً تطور البنى التي تجمع الشبكات

التلافيفية CNN لاستخراج السمات البصرية مع الشبكات المتكررة RNN و LSTMو GRUلتوليد النصوص، إضافةً إلى آليات الانتباه والتعلم المعزز والشبكات التوليدية التنافسية. وشملت المراجعة 31 دراسة بحثية اعتمدت على مجموعات بيانات مثل IU X-RAY و ChestX-ray14و CheXpert و MIMIC-CXRو PadChestوغيرها، وناقشت مقاييس تقييم النصوص مثل BLEU و METEORو ROUGE-LوCIDEr، مع الإشارة إلى أن هذه المقاييس تقيس التشابه اللغوي والدلالي ولا تضمن بالضرورة الدقة السريرية أو اكتمال المعلومات الطبية. وأبرزت المراجعة تحديات تتمثل في عدم توازن البيانات، ونقص التنوع في تقنيات التصوير، وصعوبة الحصول على تعليقات طبية موثوقة، وغياب معايير تقييم سريرية موحدة، مما يدعم ضرورة ربط أي مخرجات وصفية بأدلة مستمدة من الصورة وتجنب اعتبار التفسير اللغوي بديلًا عن التحقق الطبي

2.2 جدول الدراسات المرجعية

رقم	سنة النشر	ملخص الدراسة	مجموعة البيانات	طرق المعالجة	النموذج	النتائج
1	2026	دمج الصور والبيانات السريرية لتحسين تشخيص سرطان الثدي.	CBIS-DDSM، INbreast، BCDR-D01، CMMD	تقسيم على مستوى المريضة، واستخراج السمات ودمجها عبر الانتباه متعدد الوسائط.	CNN، ومحولات الرؤية، و-Cross Modal Attention.	دقة التحقق 94.6%، وAUC = 0.963، و AUCخارجي 0.947و0.939.
2	2026	دمج منظري CCو MLO لتحسين تشخيص سرطان الثدي.	VinDr-Mammo، INbreast	استخراج منطقة الثدي، وإزالة العضلة الصدرية، وتحسين التباين، ومحاذاة الصور.	شبكات متبقية مع Gated Cross-View Fusion وآليات الانتباه.	الدقة 92.12%على VinDr-Mammo و95.56 %على INbreast.
3	2025	محاذاة الصور والتقارير لتدريب نماذج الرؤية واللغة متعددة المناظر.	EMBED، VinDr-Mammo، RSNA-Mammo	إزالة العضلة الصدرية، والمحاذاة الهندسية، وتقسيم الصور إلى رقع، ومواءمة الصور والنصوص.	GLAM باستخدام DINOv2 وBioClinical-BERT و-Cross Attention.	تحسن في bACC و AUCضمن إعدادات Zero-shot وFew-shot؛ لا توجد أرقام موحدة.
4	2025	مقارنة استراتيجيات دمج منظري CCو MLO وتحسين التعميم بين مجموعات البيانات.	CSAW-CC، CMMD، VinDr-Mammo، RSNA KAU-BCMD، NLBS	استخراج منطقة الثدي، وتوحيد الاتجاه، والتعزيز، ودمج السمات أو التنبؤات.	MDV و DBE باستخدام معماريات CNNو ViT.	MDVمع AUC = VGG19: 0.9051؛ و DBEمع F1 = DenseNet: 0.7756و AUC = 0.8033.
5	2026	تصنيف كثافة أنسجة الثدي إلى أربع فئات وفق BI-RADS باستخدام نموذج منخفض التكلفة.	مجموعة داخلية، mini-MIAS	تغيير الحجم، والتطبيع، والتحقق المتقاطع مع فصل بيانات المريضات.	CD-CNNمع Extreme Learning Machine (ELM).	الدقة الداخلية 95.4% والخارجية 73.9%؛ الحساسية 92.5% و75.1 %على الترتيب.
6	2025	نظام متعدد المستويات والرؤى للكشف	مجموعة رئيسية، مجموعة	تقسيم الصور إلى رقع، وإنشاء خرائط للخباثة، ودمجها مع	شبكة متعددة المهام باستخدام	AUC = 0.995 للتحقق و0.933 و0.947 للاختبارين

		عن سرطان الثدي وتصنيفه وفق BI-RADSودعم القرار السريري.	مساعدة، مجموعتا اختبار خارجيتان	صور CC و.MLO	EfficientNet-B0.	الخارجيين؛ خفض الإيجابيات الكاذبة بنسبة .83.1%
7	2025	توليد تقارير إشعاعية منظمة من الصور والسياق السريري مع تقليل الهلوسات الزمنية.	MIMIC-CXR، CheXpert Plus	استخراج السياق، وتنظيم المحفزات، والضبط الدقيق باستخدام .LoRA	CheXagent-3B، MedGemma-4B، Lingshu-7B.	انخفاض الهلوسات الزمنية من 22.9% إلى 10.7%، وتحسن مقاييس F1بمقادير متفاوتة.
8	2025	تفسير قرارات الكشف عن آفات الثدي بتحديد المناطق المؤثرة في التنبؤ.	VinDr-Mammo	استخراج رقع متعددة المقاييس وإنشاء خرائط للأهمية المكانية.	CorRELAX وشبكة تعلم عميق متعددة المقاييس.	F1 = 0.8432 للتكلسات و0.7392 للكتل؛ Pointing Game = 0.6358 للتنبؤات و0.5602 لخرائط الارتباط.
9	2025	التنبؤ بكثافة الثدي وتصنيفها إلى أربع فئات وفق BI-RADS.	مجموعة رئيسية، RSNA Breast Cancer Detection	تغيير الحجم، وتحسين التباين، والتطبيع، والتعزيز، ودمج التنبؤات باستخدام Soft Voting.	مقارنة ResNet50 وInceptionV3 وDenseNet121 وXception؛ تفوق InceptionV3.	Average Precision للفئات A–D: 0.895، 0.857، 0.953، 0.952؛ و Cohen’s kappa = 0.803. خارجي.
10	2025	كشف كتل الثدي وتصنيفها إلى حميدة أو خبيثة باستخدام نقل التعلم.	CBIS-DDSM، VinDr-Mammo، INbreast، MIAS، مجموعة سريرية خاصة	تحويل DICOM إلى JPEG، وقص الحواف، وتصنيف BI-RADS 2–3 كحميد و4–5 كخبيث.	YOLOv5-CAD مع Transfer Learning.	عند النقل من CBIS-DDSM: mAP = 0.843و Precision = 0.855و Recall = 0.774؛ ومن VinDr-Mammo: 0.840 و0.829 و0.787 على الترتيب.
11	2025	كشف كتل الثدي ثم تقسيمها مكانيًا باستخدام إطار	CBIS-DDSM، INbreast	قص الحواف البيضاء غير المرغوبة.	YOLOv5n للكشف، و Depthwise SegNet للتقسيم.	mAP@0.5 = 50.3%و68.2%؛ و Dice = 89.4% و IoU = 87.0%؛ و

		خفيف من مرحلتين.				% 77.3و81.0% على الترتيب.
12	2025	مقارنة معماريات متعددة المناظر لتصنيف فحص الماموغرام كاملًا.	مجموعات ماموغرام متعددة	معالجة الصور عالية الدقة ودمج المعلومات من المناظير الأربعة.	Multi-view Graph Transformو er.	النتائج الرقمية غير متاحة في الملخص.
13	2024	توليد تقارير إشعاعية من الصور السريرية باستخدام نموذج رؤية ولغة.	IU X-Ray، MIMIC-CXR	تحسين المشفر البصري، والتدريب المشترك للصور والنصوص، والضبط الدقيق، واستخراج الملاحظات.	ClinicalBLIP باستخدام InstructBLIP وCLIP وFlan-T5- وQ-XL Former.	على IU X-Ray: METEOR ≈ 0.570 وROUGE-L ≈ 0.534؛ وعلى MIMIC-CXR: 0.365 و0.313.
14	2024	تطوير نموذج أساس للرؤية واللغة في الماموغرام لتحسين كفاءة البيانات والمتانة والتفسير.	UPMC، VinDr-Mammo، RSNA-Mammo	استخراج منطقة الثدي، وتوحيد أحجام الصور، وتعزيز أزواج CCوMLO، ومواءمة الصور والنصوص.	Mammo-CLIP باستخدام EfficientNet وBioClinicalBERT، مع Mammo-FActOR.	على AUC VinDr: = 0.76 (Zero-shot)، و0.86 (Linear Probe)، و0.88 (Fine-tuning)؛ وعلى RSNA: 0.60 و0.91؛ و mAPللكتل 0.58وللتكلسات 0.35.
15	2024	تفسير تصنيف BI-RADS للتكلسات باستخدام السمات الشعاعية والتقارير الداعمة.	صور ماموغرام تحتوي على تكلسات	تفاصيل المعالجة المسبقة غير متاحة في الملخص.	Radioport، وهو نموذج يجمع Radiomics والتقارير.	النتائج الرقمية غير متاحة في الملخص.
16	2024	دراسة تعميم تصنيف كثافة الثدي عبر تقنيات التصوير والمجموعات السكانية المختلفة.	مجموعة متعددة المراكز تشمل FFDM وDS2	تغيير حجم الصور ومقارنة التدريب على FFDMوحده بالتدريب المشترك مع DS2.	ResNet-34 باستخدام TensorFlow 2.	عند التدريب على FFDMفقط :الدقة 80.5%على FFDMو79.4 % على DS2؛ وعند التدريب المشترك : 82.3%على كليهما.
17	2023	مراجعة لأساليب توليد	IU X-Ray،	مراجعة أساليب استخراج السمات،	CNNمع RNN/LST	استعراض مقاييس BLEU

		تقارير الصور الطبية تلقائيًا باستخدام التعلم العميق.	ChestX-ray14، CheXpert، MIMIC-CXR، PadChest، DDSM وغيرها	والانتباه، والتعلم المعزز، والتوليد التنافسي.	M/GRU، وآليات Attention، وRL، وGANs.	METEOR و ROUGE-L و CIDErدون نتيجة أداء موحدة.

خلاصة

بناءً على مجمل هذه الدراسات، يتضح أن تطوير نظام متكامل لتحليل صور الماموغرام يتطلب الجمع بين الاستفادة من الصور الأربع لكل حالة، وتصميم آليات مناسبة لدمج المعلومات بين الرؤى، وبناء مهام تصنيف مستقلة لـBI-RADS وكثافة الثدي، مع إمكانية إضافة كشف المناطق المشبوهة وتقسيمها وتفسير القرارات. كما تؤكد الأدبيات أهمية تقسيم البيانات على مستوى المريضة لتجنب التسرب، ومعالجة عدم توازن الفئات، ومراقبة فرط التخصيص، وإجراء اختبارات خارجية لقياس التعميم، مع اختيار مقاييس تقييم مناسبة لكل مهمة؛ إذ لا تكفي دقة التصنيف وحدها لتقييم أداء نظام طبي متعدد المهام، بل ينبغي دعمها بمقاييس مثل AUC وF1 وSensitivity وSpecificity، وبمقاييس الكشف والتقسيم عند تطبيقهما، وبوسائل تحقق تقيّم مدى ارتباط تفسيرات النموذج بالمناطق الفعلية ذات الأهمية في صور الماموغرام.

تؤكد الدراسات السابقة فعالية نماذج الرؤية والشبكات التلافيفية العميقة والهجينة في تحسين دقة تشخيص سرطان الثدي وتصنيف كثافته وتوليد التقارير، إلا أنها تتعرض عادةً لمشكلات تتعلق بالتعميم عبر معدات تصوير مختلفة، والتحديات الحسابية في البيئات محدودة الموارد، وقلة التكامل بين التحليل البصري والتوليد اللغوي للتقارير. يقدّم مشروع Saniva نهجًا متكاملًا يجمع بين التقنيات المتقدمة متعددة الرؤى والنماذج الخفيفة لتحقيق تشخيص مبكر فعّال وقابل للتطبيق السريري الواسع.

الفصل الثالث

إدارة المشروع

الفصل الثالث ـ إدارة المشروع

1.3 المقدمة

في هذا الفصل، يتم استعراض الجوانب الإدارية والتنظيمية لمشروع Sanvia، والتي تُعد عنصرًا داعمًا لنجاح تطوير نظام تشخيص ذكي معتمد على الذكاء الاصطناعي في المجال الطبي. يركّز هذا الفصل على ميثاق المشروع، خطة العمل، وثيقة نطاق العمل (SOW)، إدارة المخاطر، وآليات التحكم بالتجارب والنماذج، بما يضمن تنفيذ المشروع بطريقة منهجية ومنظمة منذ مرحلة الإعداد وحتى الوصول إلى النتائج النهائية.

2.3 ميثاق المشروع

يُعد ميثاق المشروع وثيقة رسمية تحدد الإطار العام للمشروع وتوضح أهدافه ونطاقه، كما تمثل مرجعًا أساسيًا لاتخاذ القرارات خلال مراحل التنفيذ المختلفة.

الجدول 1.3: ميثاق المشروع

عنوان المشروع	Sanvia : AI for Early Hope		
تاريخ بدء المشروع	2026/10/13		
تاريخ انتهاء المشروع	2027/2/1		
مدير المشروع	الدكتورة ماجدة البكور		
أهداف المشروع	يهدف مشروع Sanvia إلى تطوير إطار عمل ذكي متعدد المهام لتشخيص سرطان الثدي آليًا، وذلك من خلال تحليل صور التصوير الشعاعي للثدي (Mammography) ودمج المعلومات القادمة من عدة مناظر تصويرية مختلفة. يعتمد النظام على تقنيات التعلم العميق ونماذج الذكاء الاصطناعي المتقدمة لمعالجة التحديات المرتبطة بعدم توازن البيانات وتوليد تقارير طبية تلقائية داعمة للقرار السريري		
المنهجية العامة للعمل	1. دراسة المشكلة وسير العمل السريري لتشخيص سرطان الثدي. 2. تحليل مجموعات البيانات المستخدمة وخصائصها الإحصائية. 3. تصميم بنية نموذج ذكاء اصطناعي متعددة المدخلات والمخرجات. 4. تنفيذ نماذج التعلم العميق وطبقات الدمج والانتباه. 5. تدريب النماذج وتقييم الأداء باستخدام مقاييس مناسبة. 6. تحليل النتائج وتوثيقها علميًا.		
الأدوار والمسؤوليات	المسؤولية	الدور	الاسم
	الإشراف الأكاديمي والتوجيه	مشرف	الدكتورة ماجدة البكور
	الإشراف العملي والتوجيه	مشرف	الدكتورة ماجدة البكور
	بناء النموذج وتدريبه وتقييمه	مهندس	الطالب ينال الشوفي

3.3 وثيقة نطاق العمل

وثيقة نطاق العمل (Statement of Work - SOW) هي وثيقة شاملة تُحدد نطاق العمل الخاص بالمشروع. توضح هذه الوثيقة المهام المحددة، والمخرجات المتوقعة، والجدول الزمني، والمسؤوليات. كما توفر فهمًا واضحًا لما يجب إنجازه، وأهداف المشروع، ومعايير النجاح.

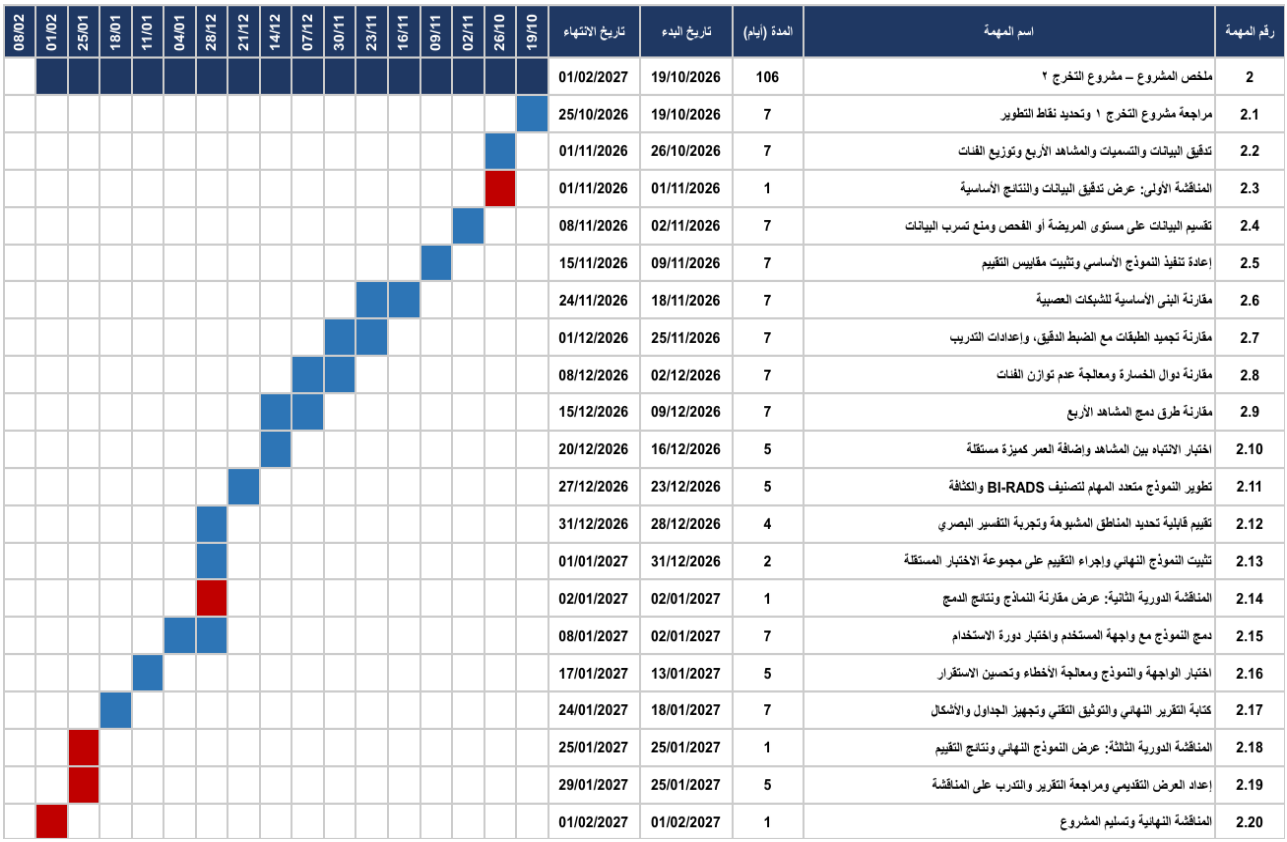
الجدول 2.3: وثيقة نطاق العمل

عنوان المشروع	Sanvia : AI for Early Hope
توصيف المشروع	يعد مشروع Sanvia نظام تشخيص آلي لسرطان الثدي يعتمد على تقنيات الذكاء الاصطناعي والتعلم العميق، وذلك من خلال تحليل صور التصوير الشعاعي للثدي (Mammography) من عدة مناظر تصويرية مختلفة. يركز المشروع على تصميم نموذج متعدد المدخلات ومتعدد المهام قادر على تصنيف حالات سرطان الثدي وفق نظام BI-RADS، وتحديد كثافة الثدي، بالإضافة إلى توليد تقارير طبية نصية تلقائية لدعم القرار السريري. يهدف المشروع إلى تقديم إطار عمل ذكي وموثوق يمكن أن يساهم في تحسين دقة وسرعة التشخيص، ودعم الأخصائيين الشعاعيين في الممارسة السريرية.
نطاق المشروع	يتضمن هذا المشروع تطوير نظام ذكاء اصطناعي بحثي يعتمد على الشبكات العصبية العميقة لمعالجة صور الماموغرام من أربعة مناظر تصويرية مختلفة باستخدام نموذج تعلم عميق متعدد المدخلات ودمج آليات انتباه ودمج متقدم لتمثيل المعلومات متعددة المناظر. بالإضافة للتعامل مع مشكلة عدم توازن توزيع الفئات في البيانات الطبية. ومن ثم تقييم النموذج باستخدام مقاييس أداء مناسبة للتطبيقات الطبية. يركز المشروع على الجانب البحثي والتجريبي في هندسة الذكاء الاصطناعي، دون تطوير نظام برمجي تشغيلي متكامل للاستخدام التجاري.
أهداف المشروع	• بناء نموذج تعلم عميق لتشخيص سرطان الثدي من صور الماموغرام. • تحقيق أداء عالٍ في تصنيف نظام BI-RADS وتصنيف كثافة الثدي. • معالجة مشكلة عدم توازن البيانات، خصوصًا الفئات النادرة. • دمج تقنيات الانتباه وطبقات الدمج لتحسين تمثيل البيانات متعددة المناظر. • توليد تقارير طبية نصية تلقائية باستخدام نماذج اللغة. • توثيق المنهجية والنتائج وفق المعايير الأكاديمية لمشاريع هندسة الذكاء الاصطناعي
مخرجات المشروع	• نموذج ذكاء اصطناعي مدرّب ومُقيّم. • نتائج تجريبية ومقاييس أداء موثقة وتقارير طبية مولدة. • التقرير النهائي (الرسالة العلمية).
التكنولوجيا والأدوات	لغة البرمجة: Python أطر عمل التعلم العميق: TensorFlow, Keras مكتبات معالجة الصور: OpenCV, Albumentations مكتبات تحليل البيانات: NumPy, Pandas, Scikit-learn أدوات التصور البياني: Matplotlib نماذج الذكاء الاصطناعي: EfficientNetB4, Chat GPT4o ,DenseNet, MobileNet, Inception الأدوات: Google Colab Pro+, Git, GitHub

الافتراضات	• توفر بيئة حوسبة سحابية مناسبة لتدريب النماذج العميقة. • إمكانية الوصول إلى مجموعة بيانات Vindr-Mammo . • استقرار المكتبات البرمجية المستخدمة أثناء فترة التنفيذ. • توفر الإشراف الأكاديمي طوال فترة العمل على المشروع.	
موارد المشروع	الموارد البشرية	
	مدير المشروع	الدكتورة ماجدة البكور
	مشرف	الدكتورة ماجدة البكور
	مطور نموذج الذكاء الاصطناعي ومعالجة البيانات والتجارب	الطالب ينال الشوفي
الجداول الزمنية	• تاريخ بدء المشروع: 2026/10/13 • المقابلة الأولى للمشروع: 2026/11/1 • المقابلة الثانية للمشروع: 2027/1/2 • مراجعة اللجنة الفنية: 2027/1/25 • الندوة النهائية للمشروع: 2027/2/15 • تاريخ انتهاء المشروع: 2027/2/15	

4.3 خطة المشروع – مخطط غانت

توضح خطة المشروع تسلسل المراحل الزمنية الرئيسية لتطوير النظام عبر مخطط غانت، بدءًا من مرحلة دراسة المشكلة والبيانات، مرورًا بتصميم النموذج والتدريب والتقييم، وانتهاءً بتوثيق النتائج وتقديم المشروع النهائي.



رقم المهمة	اسم المهمة	المدة (أيام)	تاريخ البدء	تاريخ الانتهاء
2	ملخص المشروع – مشروع التخرج ٢	106	19/10/2026	01/02/2027
2.1	مراجعة مشروع التخرج ١ وتحديد نقاط التطوير	7	19/10/2026	25/10/2026
2.2	تدقيق البيانات والتسميات والمشاهد الأربع وتوزيع الفئات	7	26/10/2026	01/11/2026
2.3	المناقشة الأولى: عرض تدقيق البيانات والنتائج الأساسية	1	01/11/2026	01/11/2026
2.4	تقسيم البيانات على مستوى المريضة أو الفحص ومنع تسرب البيانات	7	02/11/2026	08/11/2026
2.5	إعادة تنفيذ النموذج الأساسي وتثبيت مقاييس التقييم	7	09/11/2026	15/11/2026
2.6	مقارنة البنى الأساسية للشبكات العصبية	7	18/11/2026	24/11/2026
2.7	مقارنة تجميد الطبقات مع الضبط الدقيق، وإعدادات التدريب	7	25/11/2026	01/12/2026
2.8	مقارنة دوال الخسارة ومعالجة عدم توازن الفئات	7	02/12/2026	08/12/2026
2.9	مقارنة طرق دمج المشاهد الأربع	7	09/12/2026	15/12/2026
2.10	اختبار الانتباه بين المشاهد وإضافة العمر كميزة مستقلة	5	16/12/2026	20/12/2026
2.11	تطوير النموذج متعدد المهام لتصنيف BI-RADS والكثافة	5	23/12/2026	27/12/2026
2.12	تقييم قابلية تحديد المناطق المشبوهة وتجربة التفسير البصري	4	28/12/2026	31/12/2026
2.13	تثبيت النموذج النهائي وإجراء التقييم على مجموعة الاختبار المستقلة	2	31/12/2026	01/01/2027
2.14	المناقشة الدورية الثانية: عرض مقارنة النماذج ونتائج الدمج	1	02/01/2027	02/01/2027
2.15	دمج النموذج مع واجهة المستخدم واختبار دورة الاستخدام	7	02/01/2027	08/01/2027
2.16	اختبار الواجهة والنموذج ومعالجة الأخطاء وتحسين الاستقرار	5	13/01/2027	17/01/2027
2.17	كتابة التقرير النهائي والتوثيق التقني وتجهيز الجداول والأشكال	7	18/01/2027	24/01/2027
2.18	المناقشة الدورية الثالثة: عرض النموذج النهائي ونتائج التقييم	1	25/01/2027	25/01/2027
2.19	إعداد العرض التقديمي ومراجعة التقرير والتدرب على المناقشة	5	25/01/2027	29/01/2027
2.20	المناقشة النهائية وتسليم المشروع	1	01/02/2027	01/02/2027

الشكل 1.3: مخطط غانت

5.3 إدارة المخاطر

تم تحديد مجموعة من المخاطر المحتملة التي قد تؤثر على تنفيذ المشروع البحثي.

الجدول 3.3: جدول المخاطر المحتملة

رمز الخطر	وصف الخطر	التأثير	خطة التخفيف
RK-01	عدم توازن البيانات	عالٍ	استخدام استراتيجيات معالجة الاختلال
RK-02	تعقيد النموذج	متوسط	تبسيط البنية تدريجيًا
RK-03	متطلبات حوسبة عالية	عالٍ	الاعتماد على بيئة سحابية
RK-04	صعوبة التفسير السريري	متوسط	دمج التوليد النصي للتقارير

6.3 إدارة النماذج والتجارب

1. **وصف بيئة التنفيذ**
تم تنفيذ جميع مراحل التدريب والتقييم ضمن بيئة حوسبة سحابية نظرًا لحجم البيانات وتعقيد النماذج.
2. **التحكم بالإصدارات**
تم استخدام Git وGitHub لإدارة الشيفرة المصدرية، تتبع التعديلات، وضمان إمكانية الرجوع إلى الإصدارات السابقة أثناء التجارب.
3. **تتبع التجارب**
   - تم اعتماد أدوات تتبع لتسجيل أداء النماذج، بما يشمل:
   - قيم الخسارة
   - الدقة
   - F1-score
   - تطور الأداء عبر العصور التدريبية
4. **حفظ النماذج**
تم حفظ النماذج المدربة بصيغ معيارية تتيح إعادة الاستخدام وإعادة التقييم.

7.3 خطة العمل

تقوم خطة العمل المقترحة على تصميم نظام متعدد المدخلات ومتعدد المخرجات يُعرف باسم Sanvia، يهدف إلى محاكاة سير العمل السريري في تشخيص سرطان الثدي، من خلال الدمج بين التحليل البصري لصور الماموغرام والتوليد النصي للتقارير الطبية.
يتكون النظام من ثلاث طبقات رئيسية:

- طبقة المدخلات
- النواة التحليلية (Backbone)
- طبقة المخرجات

(يُستكمل التفصيل في الفصل المنهجي اللاحق)

8.3 الخلاصة

يُظهر هذا الفصل أهمية التنظيم والإدارة المنهجية في تنفيذ مشاريع هندسة الذكاء الاصطناعي، خاصة في المجالات الطبية الحساسة. إن الالتزام بخطة واضحة لإدارة المشروع، وإدارة المخاطر، وتتبع النماذج والتجارب، يسهم بشكل مباشر في موثوقية النتائج وقابلية تطبيق النظام المقترح في السياق السريري

الفصل الرابع

المنـهجيـة

الفصل الرابع - المنهجية

1.4 مقدمة

يقدم هذا الفصل المنهجية التفصيلية المُتبعة في تصميم وتنفيذ نظام .SANVIA يبدأ بمراجعة تقنية للمفاهيم الأساسية والتقنيات المستخدمة، ثم يصف مجموعة البيانات وخطوات المعالجة المسبقة، ويختتم بالبنية المعمارية الكاملة للنظام ومقاييس التقييم. تركز المنهجية على الجوانب الهندسية الدقيقة التي تُميز SANVIA عن الأنظمة الموجودة، مع التركيز على قابلية التطبيق العملي والتكرار.

2.4 مراجعة تقنية للأدبيات

تنوّعت الجهود البحثية في مجال الذكاء الاصطناعي لتشخيص سرطان الثدي عبر التصوير الشعاعي، الشبكات العصبية التلافيفية، ومحولات الانتباه، إضافة إلى توليد التقارير السريرية:

- **الشبكات العصبية التلافيفية :** استخدمت العديد من الدراسات CNNs لاستخراج السمات الهرمية من صور ماموغرام، حيث تمكنت الطبقات الضحلة من التعرف على السمات البسيطة مثل الحواف والألوان، في حين اكتشفت الطبقات العميقة الأنماط المعقدة والتشوهات الدقيقة التي قد تفوت العين البشرية. على سبيل المثال، اعتمدت دراسة [10] شبكة CD-CNN لتصنيف كثافة الثدي مع طبقة ELM، محققة دقة 95.4% على البيانات الداخلية و73.9% على مجموعة mini-MIAS الخارجية، ما أظهر قدرة CNNs على التعلم حتى في البيئات محدودة الموارد.
- **آليات الانتباه :** استخدمت بعض الدراسات Self-Attention لحساب العلاقات بين جميع عناصر المدخلات، و Cross-Attention لدمج المناظر المختلفة للثدي CC وMLO على سبيل المثال، طورت دراسة [16] استراتيجيتين لدمج مناظير CC وMLO، محققة AUC يصل إلى 0.9051 باستخدام VGG19 و0.8042 باستخدام ResNet50، مع ثبات أفضل للاستراتيجية DBE عبر مجموعات بيانات متعددة.
- **التعلم بالنقل وإعادة الضبط:** استفادت الدراسات من النماذج المدربة مسبقًا مثل ImageNet لتسريع التعلم على مجموعات بيانات ماموغرام الأصغر. وقد استخدمت دراسة [11] شبكة متعددة المهام لاستخراج الآفات وEfficientNet-B0 للتصنيف النهائي، مسجلة AUC تصل إلى 0.995 على التحقق الداخلي و0.933-0.947 على الاختبار الخارجي، مع خفض كبير في الإيجابيات الكاذبة.
- **توليد التقارير السريرية :** ركزت بعض الدراسات على أتمتة التقارير الطبية باستخدام نماذج اللغة، مثل دراسة [12] التي استخدمت نموذج ClinicalBLIP المبني علىInstructBLIP ، محققة قيم METEOR تصل إلى 0.570 و ROUGE-Lإلى 0.534 على مجموعةIU X-RAY ، مما أبرز إمكانية توليد نصوص سريرية دقيقة وآلية.
- **نماذج أساسية متعددة الوسائط :** قامت دراسة [13] بتطوير Mammo-CLIP المدرّب على أزواج صور-تقارير، محققًا AUC يصل إلى 0.91 في تصنيف السرطان بعد ضبط دقيق كامل،

و0.88 في تصنيف الكتل، مع إمكانية توطين السمات دون الحاجة لصناديق إحاطة، ما يمثل خطوة نحو نماذج أكثر مرونة واستقلالية.

3.4 الفجوات على المستويين المعرفي والتطبيقي

تشـــير الأدبيات الحالية إلى وجود فجوات على مســـتويين رئيســـيين في مجال الذكاء الاصـــطناعي لتشخيص سرطان الثدي عبر ماموغرام.

الفجوة المعرفية: هناك نقص في الدراســـات التي تســـتكشـــف العلاقة التفاعلية بين المناظر الأربعة القياســية للثدي L_CC ، L_MLO، R_CC، R_MLO باســتخدام آليات الانتباه المتقدمة. معظم الأبحاث تتعامل مع كل منظر بشـكل منفصـل أو تلجأ إلى طرق دمج بسـيطة مثل التجميع أو المتوسـط الحسابي، ما يقلل من القدرة على الاستفادة الكاملة من المعلومات المتكاملة بين المناظر المختلفة.

الفجوة التطبيقية: فهناك غياب للأنظمة الشـاملة التي تجمع بين جميع عناصـر سـير العمل السـريري: التشخيص الآلي، التفسير البصري، وتوليد التقارير الطبية المفصلة. معظم النماذج الحالية تقتصر على مرحلة واحدة، مثل تصنيف BI-RADS أو تقييم كثافة الثدي، دون ربطها بتوليد تقرير سريري يمكن استخدامه مباشرة في الممارسة الطبية، مما يحد من فاعلية التطبيقات العملية في البيئات السريرية.

4.4 منهجية العمل

تتبع منهجية هذا البحث النهج التجريبي مع تصـــميم هندســـي تكراري. تم العمل حســـب الخطوات الرئيسية التالية:

1. **جمع وتحضير البيانات :**تنظيف، توحيد، وتوازن
2. **بناء النموذج :**تصميم البنية المعمارية مع آليات الدمج
3. **التدريب :**استراتيجيات متقدمة لمعالجة الاختلال
4. **التقييم :**مقاييس شاملة وتحليل الأخطاء
5. **توليد التقارير :**تكامل LLMs API

5.4 مجموعة المعطيات المستخدمة

Vindr-Mammo Dataset 1.5.4

تم اختيار مجموعة بيانات Vindr-Mammo [15] كمصدر أساسي للبيانات نظراً لخصائصها المتميزة:

الجدول 4.4: خصائص مجموعة بيانات Vindr-Mammo

الخاصية	التفاصيل
المصدر	مستشفى فيتنامي كبير(Bach Mai Hospital)
الفترة	2018-2020
عدد الصور	20,000 صورة رقمية
عدد الدراسات	5,000 دراسة فريدة
التوزيع الجنسي	100 % نساء
الفئة العمرية	40-70 سنة (متوسط 52.3)
الأبعاد	متغيرة (تقريبا 3024×2016)
التنسيق	DICOM
التسميات	BI-RADS, Density, Findings (نصية)

2.5.4 خصائص التسميات

في تحليل صور ماموغرام، تُصنف الحالات عادةً وفق معيار BI-RADS وكثافة النسيج الثدي Breast Density، وهما عنصران أساسيان لفهم تحديات النماذج الذكية ودقتها:

- **تصنيف BI-RADS:** يحدد مستوى الشك في وجود أورام سرطانية ويقسم الحالات إلى خمس فئات، مع توزيع غير متساوٍ للغاية، مما يمثل تحديًا للأنظمة الذكية بسبب الاختلال الكبير في البيانات:
  - **1 سلبي:** يمثل 67.5% من الحالات، أي أن غالبية الصور لا تحتوي على أي مؤشرات مرضية.
  - **2 حميد:** 28.3% من الحالات، تشمل التغيرات غير السرطانية مثل الأكياس أو التكلسات البسيطة.
  - **3 غالباً حميد:** 3.9%، تشير إلى تغييرات صغيرة تحتاج إلى متابعة دورية، مع احتمال ضئيل للإصابة بالسرطان.
  - **4 مشتبهة:** 0.27% فقط من الحالات، تمثل فئة حرجة تتطلب إجراء خزعة للتأكد من التشخيص.
  - **5 شديدة الاشتباه:** 0.03%، حالات نادرة جدًا لكنها حرجة، تمثل أعلى مستوى من الشك السرطاني.

هذا التوزيع يوضح اختلال الفئات، حيث تمثل الفئات الحرجة الأقل تكرارًا تحديًا كبيرًا لنماذج التعلم الآلي، إذ تميل الشبكات العصبية إلى التنبؤ بالفئات الأكثر تكرارًا، ما قد يؤدي إلى تفويت الحالات السرطانية النادرة.

- **كثافة الثدي:** تصف نسبة النسيج الغدي مقابل النسيج الدهني في الثدي، وهو عامل مهم لأن كثافة الثدي العالية قد تخفي الأورام الصغيرة، مما يزيد صعوبة التشخيص:
  - **A دهني بالكامل:** 12%، نسيج رقيق يسمح برؤية واضحة للكتل المحتملة.
  - **B نسيج غدي/دهني متناثر:** 38%، معظم الصور واضحة ولكن بعض المناطق قد تتطلب انتباهًا إضافيًا.
  - **C غير موحد:** 41%، يضم نسيج غدي كثيف بشكل غير متجانس، ما يجعل كشف الأورام أصعب.
  - **D كثيف:** 9%، أكثر الفئات تحديًا للتشخيص البصري والآلي، حيث يمكن أن تختفي الكتل الصغيرة داخل النسيج الكثيف.

3.5.4 التحديات في البيانات

تواجه مجموعات بيانات التصوير الشعاعي للثدي عدة تحديات جوهرية تؤثر على فعالية النماذج الذكية ودقتها في التشخيص:

- **الاختلال الشديد في الفئات:**

الفئات الحرجة مثل BI-RADS 4 (مشتبهة) و BI-RADS 5 (شديدة الاشتباه) تمثل أقل من 0.3% من جميع العينات مجتمعة، بينما تشكل الفئات الطبيعية والحميدة غالبية البيانات. هذا الاختلال يجعل النماذج التقليدية متحيزة نحو الفئات الأكثر شيوعًا، ويضعف قدرتها على كشف الحالات الحرجة التي تتطلب تدخلًا سريعًا.

- **التسميات النصية:**

في بعض قواعد البيانات، يتم تسجيل تصنيف BI-RADS في حقل نصي مثل Findings بدلاً من حقل رقمي جاهز، مما يتطلب معالجة نصية مسبقة لاستخراج التسمية بشكل دقيق، غالبًا باستخدام تقنيات Regex أو معالجة اللغة الطبيعية. أي خطأ في هذه المرحلة قد يؤدي إلى أخطاء في التسمية التدريبية ويؤثر على أداء النموذج.

- **المناظر المفقودة:**

قد لا تحتوي بعض الدراسات على كل المناظر الأربعة القياسية L_CC, L_MLO, R_CC, R_MLO هذا النقص يمثل تحديًا في دمج المعلومات بين المناظر المختلفة، حيث تعتمد العديد من النماذج على وجود جميع المناظر للحصول على نتائج دقيقة.

- **تباين جودة الصور:**

تختلف جودة الصور بشكل كبير بين الأجهزة والمراكز الطبية، سواء من حيث الإضاءة، التباين، أو دقة الاستشعار. هذا التباين يؤدي إلى صعوبة في تدريب النماذج، إذ أن النموذج قد يتعلم خصائص غير متعلقة بالمرض بدلًا من السمات التشخيصية الحقيقية.

6.4 تحضير مجموعة المعطيات

1.6.4 تنظيف البيانات

- استخراج تصنيف BI-RADS من النصوص:
استخدام Regex لاستخراج الرقم من نصوص مثل "BI-RADS 3".

- تحويل كثافة الثدي (Density) إلى ترميز رقمي:
A → 0
B → 1
C → 2
D → 3

- معالجة القيم غير الصالحة:
استبدال القيم مثل 'N/A' بالوسيط (Median) للفئة المعنية.

- إزالة القيم غير المنطقية أو الناقصة:
الدراسات التي لا تحتوي على صور. او تصنيفات BI-RADS خارج النطاق 1–5. او أعمار خارج المدى المنطقي 20–100 سنة.

2.6.4 دمج البيانات الجدولية

- استخراج العمر:
يتم الحصول على العمر من Metadata لملفات DICOM أو سجلات المرضى.

- تقييس العمر (Normalization):

استخدام MinMaxScaler المعادلة (1.4) لتحويل القيم إلى نطاق محدد:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \qquad (1.4)$$

حيث:

- x :هو القيمة الأصلية للمتحول أو الخاصية التي نريد تقييسها.
- $x_{\min}$:هو أصغر قيمة للمتحول xفي مجموعة البيانات.
- $x_{\max}$:هو أكبر قيمة للمتحول xفي مجموعة البيانات.
- x_{norm} :هو القيمة بعد التقييس، بحيث تصبح جميع القيم في النطاق $[0, 1]$.

3.6.4 إنشاء View Mapping

1. **تجميع المناظر لكل دراسة:** لكل مريض، يتم تجميع أربعة مناظر أساسية:
   - L_CC: Left Cranio-Caudal
   - L_MLO: Left Medio-Lateral Oblique
   - R_CC: Right Cranio-Caudal
   - R_MLO: Right Medio-Lateral Oblique

2. **معالجة المناظر المفقودة:** إذا كان أحد المناظر مفقوداً:
   - يتم استخدام Placeholder أسود بنفس أبعاد الصورة (قيم البكسل = 0).
   - إضافة قناة Binary Mask لكل منظر، تُشير إلى وجود المنظر (0) أو غيابه (1).

4.6.4 معالجة عدم توازن الفئات

تُعد مشكلة اختلال توزيع الفئات من أبرز التحديات في مجموعات بيانات ماموغرام، حيث تمثل الفئات الحرجة مثل BI-RADS 4 و5 نسبة ضئيلة للغاية من البيانات، مما يجعل النماذج تميل إلى التحيز نحو الفئات الأكثر تكرارًا مثل BI-RADS 1 و2. لمعالجة هذه المشكلة، تم تطبيق استراتيجيتين رئيسيتين Effective Number Weighting وOversampling للفئات النادرة.

- **Effective Number Weighting**

تعتمد هذه الطريقة على حساب وزن كل فئة وفقًا لعدد العينات المتاحة لها بطريقة تقلل من تأثير الفئات الكبيرة وتزيد من أهمية الفئات الصغيرة. الصيغة المستخدمة المعادلة (2.4).

$$w_i = \frac{1 - \beta}{1 - \beta^{n_i}} \qquad (2.4)$$

حيث:

- n_i هو عدد العينات في الفئة i
- β هو معامل ضبط، تم اختياره في هذه الدراسة $\beta = 0.9$

الوزن الناتج لكل فئة يتم دمجه مع دالة الخسارة (Loss Function) لتقوية تأثير العينات النادرة خلال عملية التدريب، مما يساعد النموذج على التركيز على الفئات الحرجة وتجنب التحيز نحو الفئات الأكثر شيوعًا.

- **Oversampling للفئات النادرة**

نظرًا للتمثيل الضئيل جدًا لفئتي BI-RADS 4 و5، تم استخدام تقنية Oversampling هندسي مدعومة بالـ Augmentation لزيادة عدد العينات لكل فئة إلى مستوى موحد تقريبًا (حوالي 600 عينة لكل فئة). التفاصيل:

- BI-RADS 4: من 54 عينة فقط إلى 600 عينة، أي زيادة بمقدار حوالي 11 ضعف.
- BI-RADS 5: من 15 عينة فقط إلى 600 عينة، أي زيادة بمقدار 40 ضعف.
- BI-RADS 3: تمت زيادة عدد العينات إلى 600 عينة لتحقيق توازن أفضل مع الفئات الأكثر.
- BI-RADS 1,2: لم يتم تغيير عدد العينات، ولكن النسب المئوية للفئات الجديدة تغيرت قليلًا نتيجة زيادة العينات النادرة.

الجدول 5.4: BI-RADS Oversampling

الفئة	العدد الأصلي	النسبة الأصلية	العدد بعدOversampling	النسبة الجديدة
BI-RADS 1	3,375	67.5%	3,375	51.2%
BI-RADS 2	1,415	28.3%	1,415	21.5%
BI-RADS 3	195	3.9%	600	9.1%
BI-RADS 4	54	0.27%	600	9.1%
BI-RADS 5	15	0.03%	600	9.1%
المجموع	5,054	100%	6,590	100%

- **تطبيق تقنيات الـAugmentation**

لتحقيق Oversampling هندسي فعال، تم استخدام مكتبة Albumentation لتوليد عينات جديدة من الصور الأصلية بطريقة عشوائية ومتنوعة، مع احتمال تطبيق التعديلات بنسبة 85%. العمليات المستخدمة شملت:

- تحويلات هندسية:
  - تدوير الصورة بزاوية ±15°
  - ShiftScaleRotate لتغيير الموقع والحجم بنسبة ±10%
- تحسينات لونية:
  - RandomBrightnessContrast لضبط السطوع والتباين ضمن حدود ±20%
  - CLAHE لتوضيح التباين المحلي، clip_limit=4.0
- تأثيرات الضبابية:
  - GaussianBlur بحد أقصى 3 بكسل
  - MotionBlur بحد أقصى 3 بكسل
- تشوهات هندسية:
  - GridDistortion لتشويه الشبكة بنسبة تصل إلى 15%
- إضافة ضوضاء:
  - GaussNoise مع نطاق تباين 10–50

تهدف هذه العمليات إلى زيادة تنوع البيانات، تحسين قدرة النموذج على التعميم، والتقليل من الإفراط في التكيف مع عينات محدودة، مع الحفاظ على السمات التشخيصية الهامة للثدي.

7.4 البيئة التقنية والتنفيذية

1.7.4 الأجهزة والبنية التحتية

تم تنفيذ جميع مراحل المعالجة والتدريب باستخدام بيئة حوسبة سحابية، نظرًا لحجم البيانات ومتطلبات التدريب العميق:

- **منصة التنفيذ:**

تم الاعتماد على Google Colab Pro+، خلال جلسات التدريب طويلة المدى، لما توفره من وقت تشغيل أطول واستقرار أعلى مقارنة بالنسخة المجانية.

- **وحدة المعالجة الرسومية:**

تم استخدام NVIDIA A100 بذاكرة فيديو 80 GB VRAM، وهي مناسبة لتدريب نماذج الشبكات العصبية الالتفافية (CNNs) متعددة المدخلات، خاصة عند التعامل مع صور طبية عالية الدقة.

- **الذاكرة العشوائية:**

تم توفير 250 GB RAM ضمن بيئة Colab Pro+، مما ساعد في تحميل مجموعات البيانات، وتنفيذ عمليات الـAugmentation ، ودمج البيانات الجدولية دون اختناقات في الذاكرة.

- **التخزين:**

تم استخدام Google Drive بسعة تخزين تقارب 15 GB لحفظ:

  - صور ماموغرام
  - ملفات CSV
  - النماذج المدربة
  - نتائج التجارب والتقارير النهائية

كما ساهم التكامل المباشر بين Colab وGoogle Drive في تسهيل إدارة البيانات واستمرارية العمل بين الجلسات

2.7.4 البرمجيات والمكتبات

تم اختيار البرمجيات والمكتبات بعناية لضمان الأداء، التوافق، ودعم أحدث تقنيات التعلم العميق. يوضح الجدول التالي المكونات الرئيسية المستخدمة:

الجدول 6.4: البرمجيات والمكتبات

الاستخدام	الإصدار	المكون
لغة البرمجة الأساسية	3.12	Python
إطار العمل الرئيسي لبناء وتدريب نماذج Deep Learning	2.19	TensorFlow
واجهة عالية المستوى لتصميم النماذج	3.0	Keras
تطبيق Augmentation متقدم على الصور	1.3	Albumentations
المعالجة المسبقة للصور	4.8	OpenCV
حساب المقاييس الإحصائية ومقاييس الأداء	1.3	Scikit-learn
العمليات العددية والمصفوفية	1.24	NumPy
معالجة وتنظيم البيانات الجدولية	2.0	Pandas
التصور البياني للنتائج	3.7	Matplotlib
توليد ملفات PDF للتقارير	3.6	ReportLab
استخدام GPT-4o لتوليد التقرير	Latest	OpenAI API

3.7.4 إدارة النماذج والتجارب

لضمان التنظيم، التتبع، وإمكانية إعادة تنفيذ التجارب، تم اعتماد مجموعة من الممارسات القياسية في إدارة النماذج:

- **التحكم بالإصدارات**

  تم استخدام Git مع GitHub لإدارة الشيفرة المصدرية، تتبع التغييرات، والرجوع إلى الإصدارات السابقة عند الحاجة.

- **تتبع التجارب:**
  - TensorBoard لمراقبة:
    - قيم الخسارة (Loss)

- الدقة (Accuracy)
- F1-score
- تطور الأداء عبر العصور(Epochs)

- CSV Logging لحفظ نتائج كل تجربة بشكل منظم وقابل للتحليل لاحقًا.

- **حفظ النماذج:**

تم حفظ النماذج النهائية بصيغة (.h5) HDF5، لما توفره من توافق واسع وسهولة في التحميل وإعادة الاستخدام.

- **Checkpointing:**

تم تفعيل آلية Model Checkpointing لحفظ أفضل نموذج تلقائيًا اعتمادًا على أفضل قيمة لـ validation F1-score، مما يضمن الاحتفاظ بالنموذج الأكثر توازنًا بين الدقة والاستدعاء، خصوصًا في ظل اختلال توزيع الفئات.

8.4 المنهجية المقترحة

1.8.4 النظرة العامة

تعتمد المنهجية المقترحة على تصميم نظام متعدد المدخلات ومتعدد المخرجات يُعرف باسم Sanvia، يهدف إلى محاكاة سير العمل السريري في تحليل صور الماموغرام، من خلال الدمج بين التحليل البصري، البيانات السريرية، والتوليد النصي للتقارير الطبية.

يتكوّن النظام من ثلاث طبقات رئيسية: المدخلات، النواة التحليلية، والمخرجات، كما يلي:

1. **المدخلات:**

- **صور ماموغرام**

أربع صور لكل دراسة تمثل المناظر القياسية:

- L_CC (Left Cranio-Caudal)
- L_MLO (Left Medio-Lateral Oblique)
- R_CC (Right Cranio-Caudal)
- R_MLO (Right Medio-Lateral Oblique)

يتم توحيد أبعاد جميع الصور إلى (3 × 768 × 768) لضمان التوافق مع بنية الشبكة العصبية المستخدمة، مع الحفاظ على المعلومات التشريحية الأساسية.

- **البيانات الجدولية:**

تشمل:

  - العمر: قيمة عددية واحدة تمثل عمر المريضة بعد التطبيع.
  - علامات القيم المفقودة : أربع قيم ثنائية تشير إلى وجود أو غياب كل منظر من مناظر التصوير ونقص او وجود معلومات العمر، مما يسمح للنموذج بأخذ نقص المعلومات بعين الاعتبار أثناء التنبؤ.

2. **المخرجات:**

- **تصنيف BI-RADS:**

متجه احتمالات مكوّن من 5 فئات يتم توليده باستخدام دالة Softmax، بحيث يعكس درجة الاشتباه السريري لكل دراسة.

- **تصنيف كثافة الثدي (Breast Density):**

متجه احتمالات من 4 فئات (Density A–D)، أيضًا باستخدام Softmax، نظرًا لأهمية الكثافة في تفسير صور الماموغرام وتقدير المخاطر.

- **تقرير طبي نصي:**

يتم توليده باستخدام واجهة برمجية لنماذج اللغة الكبيرة (LLM API)، ويعتمد على مخرجات التصنيف والتفسير البصري لتقديم وصف نصي قريب من التقارير السريرية الحقيقية.

7.8.4 معمارية النموذج الكلية

البنية الكاملة للنموذج طبقةً بطبقة، بدءًا من المدخلات الصورية وانتهاءً بالمخرجات متعددة المهام.

- **طبقة الإدخال**

تستقبل أربع صور ماموغرافي لكل دراسة، تمثل المناظر القياسية الأربعة، مما يتيح للنموذج الاطلاع على السياق التشريحي الكامل.

- **EfficientNetB4 (Backbone)**

تُستخدم هذه الشبكة الالتفافية لاستخراج السمات العميقة من كل منظر على حدة، منتجة خرائط سمات غنية بتمثيلات مكانية عالية المستوى، مع عدد معاملات معتدل نسبيًا.

- **Global Average Pooling**

تقلل الأبعاد المكانية لخرائط السمات وتحولها إلى متجهات مدمجة، مما يقلل الحمل الحسابي ويحد من الحساسية للموقع الدقيق للآفات.

- **طبقة Cross-Attention**

تُستخدم لدمج المعلومات بين المناظر المتناظرة CC وMLO، حيث تتعلم العلاقات التكميلية بين المنظرين بدل التعامل معهما كمدخلات مستقلة.

- **Gated Fusion Layer**

تعمل كآلية تحكم تسمح للنموذج بتوزين مساهمة كل منظر ديناميكيًا، مع تقليل تأثير المناظر ذات الجودة الضعيفة أو غير المكتملة.

- **Concatenate دمج الجانبين**

يتم دمج تمثيلات الجانبين الأيمن والأيسر في متجه واحد، مما يتيح الاستفادة من التماثل التشريحي بين الثديين.

- **Tabular Encoder**

يعالج البيانات الجدولية (مثل العمر ومؤشرات القيم المفقودة) ويحوّلها إلى تمثيل عددي قابل للدمج مع السمات البصرية.

- **Concatenate Final**

يتم دمج السمات البصرية والجدولية في تمثيل موحد يعكس جميع مصادر المعلومات المتاحة.

- **Shared Dense Layer**

تُنتج تمثيلًا مشتركًا بُعده 256، يُستخدم كأساس للتعلّم متعدد المهام.

- **رؤوس الإخراج**

تقوم كل منها بإجراء التصنيف الخاص بمهمتها باستخدام طبقات مستقلة، مع الحفاظ على الترابط المعرفي عبر التمثيل المشترك.

يبلغ العدد الكلي لمعاملات النموذج حوالي 23.4مليون معامل، وهو توازن مدروس بين القدرة التمثيلية والكفاءة الحسابية، مما يجعله مناسبًا للتدريب على بيانات طبية عالية الدقة مع موارد حوسبة محدودة نسبيًا.

9.4 مقاييس الأداء

1.9.4 مقاييس التصنيف الأساسية

لضمان دقة وفعالية النموذج، تم استخدام مجموعة من مقاييس الأداء المهمة، وهي كالتالي:

- **الدقة (Accuracy) :** نسبة عدد الحالات التي تم تصنيفها بشكل صحيح إلى العدد الإجمالي للحالات، المعادلة رقم (3,4).

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \qquad (3.4)$$

- **قيمة التنبؤ الإيجابي (Precision) :** تمثل نسبة الإيجابيات الحقيقية إلى مجموع الإيجابيات الحقيقية والإيجابيات الزائفة. تعكس مدى دقة النموذج في التنبؤ بالإيجابيات، المعادلة رقم (4,4).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \qquad (4.4)$$

- **الاسترجاع (Recall) :** تمثل نسبة الإيجابيات الحقيقية إلى مجموع الإيجابيات الحقيقية والسلبيات الزائفة. تعكس قدرة النموذج على اكتشاف جميع الحالات الإيجابية، المعادلة رقم (5,4).

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \qquad (5.4)$$

- **F1 Score:** تستخدم لتقييم توازن الأداء بين الدقة والاسترجاع، حيث تعتبر الأهم في الحالات التي يكون فيها توزيع الفئات غير متوازن، المعادلة رقم (6,4).

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \qquad (6.4)$$

حيث:

- TP (True Positive): الحالات الإيجابية المصنفة بشكل صحيح
- TN (True Negative): الحالات السلبية المصنفة بشكل صحيح
- FP (False Positive): حالات سلبية صُنّفت خطأ كإيجابية
- FN (False Negative): حالات إيجابية لم يتم اكتشافها

- **مصفوفة الالتباس (Confusion Matrix) :** تُظهر توزيع التنبؤات الصحيحة والخاطئة لكل فئة، مما يساعد في فهم أداء النموذج بشكل أفضل وتحديد الأنماط الأخطاء الشائعة.

2.9.4 مقاييس متعددة الفئات

- **Macro-Average** متوسط غير مرجح لجميع الفئات (يعطي كل فئة وزناً متساوياً)
- **Weighted-Average** متوسط مرجح بحجم الفئة

References المراجع

[1] World Health Organization. (2023). *Breast Cancer: Key Facts*. WHO Cancer Fact Sheets.

[2] Althubiti, M. A., & Niyazi, M. (2022). Breast cancer in Saudi Arabia: Incidence, trends, and risk factors. *Saudi Medical Journal, 43*(1), 1–8.

[3] American College of Radiology. (2022). *BI-RADS Atlas* (5th ed.). American College of Radiology.

[4] Elmore, J. G., et al. (2015). Diagnostic concordance among pathologists interpreting breast biopsy specimens. *JAMA, 313*(11), 1122–1132.

[5] World Health Organization. (2023). *Global Strategy on Human Resources for Health: Workforce 2030*. WHO.

[6] Ong, M. S., & Mandl, K. D. (2015). National expenditure for false-positive mammograms and breast cancer overdiagnoses estimated at $4 billion a year. *Health Affairs, 34*(4), 576–583.

[7] McKinney, S. M., et al. (2020). International evaluation of an AI system for breast cancer screening. *Nature, 577*(7788), 89–94.

[8] Nguyen, H. T., et al. (2023). VinDr-Mammo: A large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography. *Scientific Data*.

[9] Shen, L., et al. (2021). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports, 11*(1), 1–11.

[10] Wu, N., et al. (2022). Deep neural networks improve radiologists' performance in breast cancer screening. *IEEE Transactions on Medical Imaging, 39*(4), 1184–1194.

[11] Zhang, Y., et al. (2023). Multi-task learning for simultaneous breast cancer detection and density estimation. *Medical Image Analysis, 82*, 102684.

[12] Kumar, V., et al. (2023). A comparative study of deep learning models for breast cancer detection in mammograms. *Biomedical Signal Processing and Control, 79*, 104071.

[13] Ibrahim, A. M., Li, J., Akhtar, F., Chaudhary, A. A., Ali, M. A. M., Khan, H., & Osman, M. (2026). A multi-modal deep learning framework for enhanced breast cancer diagnosis using mammograms and clinical data. *Scientific Reports*.

[14] Surulimani Ramaraj, A. S. C., Rajaguru, H., Dhanaraj, R. K., et al. (2026). Deep-learning based adaptive fusion of CC and MLO views for improved mammographic cancer diagnosis. *MethodsX*.

[15] Du, Y., Chen, L., & Dvornek, N. C. (2025). Geometry-Guided Local Alignment for Multi-View Visual Language Pre-Training in Mammography. In *Proceedings of MICCAI 2025*.

[16] Abdikenov, B., Zhaksylyk, T., Imasheva, A., Orazayev, Y., & Karibekov, T. (2025). Innovative Multi-View Strategies for AI-Assisted Breast Cancer Detection in Mammography. *Journal of Imaging, 11*(8), 247.

[17] da Rocha, N. C., Barbosa, A. M. P., et al. (2026). Enhancing Breast Density Assessment in Mammograms Through Artificial Intelligence. *Journal of Imaging Informatics in Medicine*.

[18] Tan, H., Wu, Q., et al. (2025). Mammography-Based Artificial Intelligence for Breast Cancer Detection, Diagnosis, and BI-RADS Categorization Using Multi-View and Multi-Level Convolutional Neural Networks. *Insights into Imaging*.

[19] Kang, S., Lee, D. B., et al. (2025). Automated Structured Radiology Report Generation with Rich Clinical Context. *arXiv*.

[20] Mellado, et al. (2025). Identifying clinically relevant findings in breast cancer using deep learning and feature attribution on local views from high-resolution mammography. *PubMed/PMC*.

[21] Chen, C., Wang, E., Wang, V. Y., Chen, X., Feng, B., Yan, R., Zhu, L., et al. (2025). Deep learning prediction of mammographic breast density using screening data. *Scientific Reports*.

[22] Karaca Aydemir, B. K., Telatar, Z., Güney, S., et al. (2025). Detecting and classifying breast masses via YOLO-based deep learning. *Neural Computing and Applications*.

[23] Manolakis, D., Bizopoulos, P., Lalas, A., et al. (2025). A Two-Stage Lightweight Deep Learning Framework for Mass Detection and Segmentation in Mammograms Using YOLOv5 and Depthwise SegNet. *Journal of Imaging Informatics in Medicine*.

[24] Manigrasso, F., et al. (2025). Mammography classification with multi-view deep learning techniques: Investigating graph and transformer-based architectures. *Medical Image Analysis*.

[25] Ji, J., Hou, Y., Chen, X., Pan, Y., & Xiang, Y. (2024). Vision-Language Model for Generating Textual Descriptions From Clinical Images: Model Development and Validation Study. *JMIR Formative Research*.

[26] Ghosh, S., Poynton, C. B., Visweswaran, S., & Batmanghelich, K. (2024). Mammo-CLIP: A Vision Language Foundation Model to Enhance Data Efficiency and Robustness in Mammography. In *Proceedings of MICCAI 2024*.

[27] Pang, T., Li, P., & Zhao, L. (2023). A Survey on Automatic Generation of Medical Imaging Reports Based on Deep Learning. *BioMedical Engineering OnLine*.

[28] Pang, T., Wong, J. H. D., Ng, W. L., Chan, C. S., Wang, C., Zhou, X., & Yu, Y. (2024). Radioport: A radiomics-reporting network for interpretable deep learning in BI-RADS classification of mammographic calcification. *Physics in Medicine & Biology*.

[29] Khara, G., Trivedi, H., Newell, M. S., Patel, R., Rijken, T., Kecskemethy, P., & Glocker, B. (2024). Generalisable deep learning method for mammographic density prediction across imaging techniques and self-reported race. *Communications Medicine*.

.

Syrian Private University
Faculty of Engineering
Department of Artificial intelligence & Data science

Sanvia – AI for Early Hope

A Thesis Prepared for the Fulfillment of the Requirements for the Senior Project 2 in the Artificial Intelligence and Data Science Department

Prepared by:

Yanal Emad Alshoufi

Supervisors:

Dr. Eng. Majida Albakoor

Academic Year 2026/2027